

ESTADÍSTICA III

TALLER 10: MODELOS ARIMA

Considere la serie en el archivo ARIMA110.SIMUL.txt, un conjunto de $N=201$ observaciones obtenidas por simulación. La gráfica de la serie, de su primera diferencia y de sus respectivas ACFs son presentadas en la Figura 1:

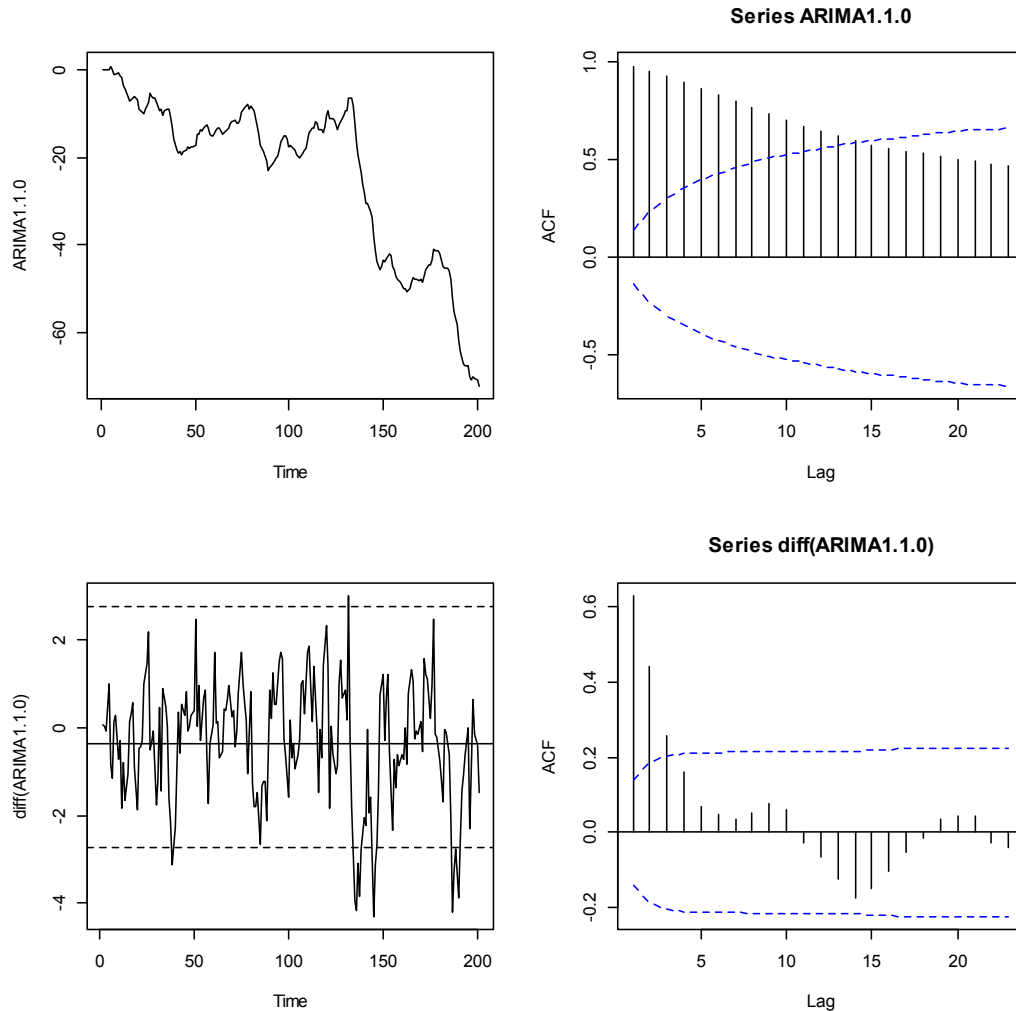


Figura 1: Serie original, su primera diferencia y sus respectivas ACFs

- ¿La serie original proviene de un proceso estacionario? ¿por qué?
- ¿La primera diferencia de la serie es estacionaria? ¿por qué? ¿será necesaria una segunda diferencia?
- Considerando sólo los primeros $n=191$ observaciones, realice la identificación de modelos ARIMA usando las siguientes herramientas
 - ACF y PACF de la serie de los $n=191$ primeros datos, diferenciada apropiadamente
 - EACF de la serie de los $n=191$ primeros datos, diferenciada apropiadamente con máximo $p=7$, $q=13$.
 - La función `auto.arima()` aplicada a la serie de los $n=191$ primeros datos, diferenciada apropiadamente
 - La función `auto.arima()` aplicada a la serie de los $n=191$ primeros datos
 - La función `autoarmafit()` aplicada a la serie de los $n=191$ primeros datos, diferenciada apropiadamente
 - La función `armasubsets()` aplicada a la serie de los $n=191$ primeros datos, diferenciada apropiadamente

- d) Para cada modelo identificado, escriba su ecuación teórica, ajuste el modelo con los $n=191$ primeros datos y valide supuestos
- e) Pronostique los últimos 10 datos de la serie
- f) Compare los modelos con base en ajuste, pronóstico y validez de supuestos (gráficos residuos, ACF, PACF, Ljung-Box y normalidad con Shapiro Wilk). ¿Cuál modelo se recomienda?

Resultados

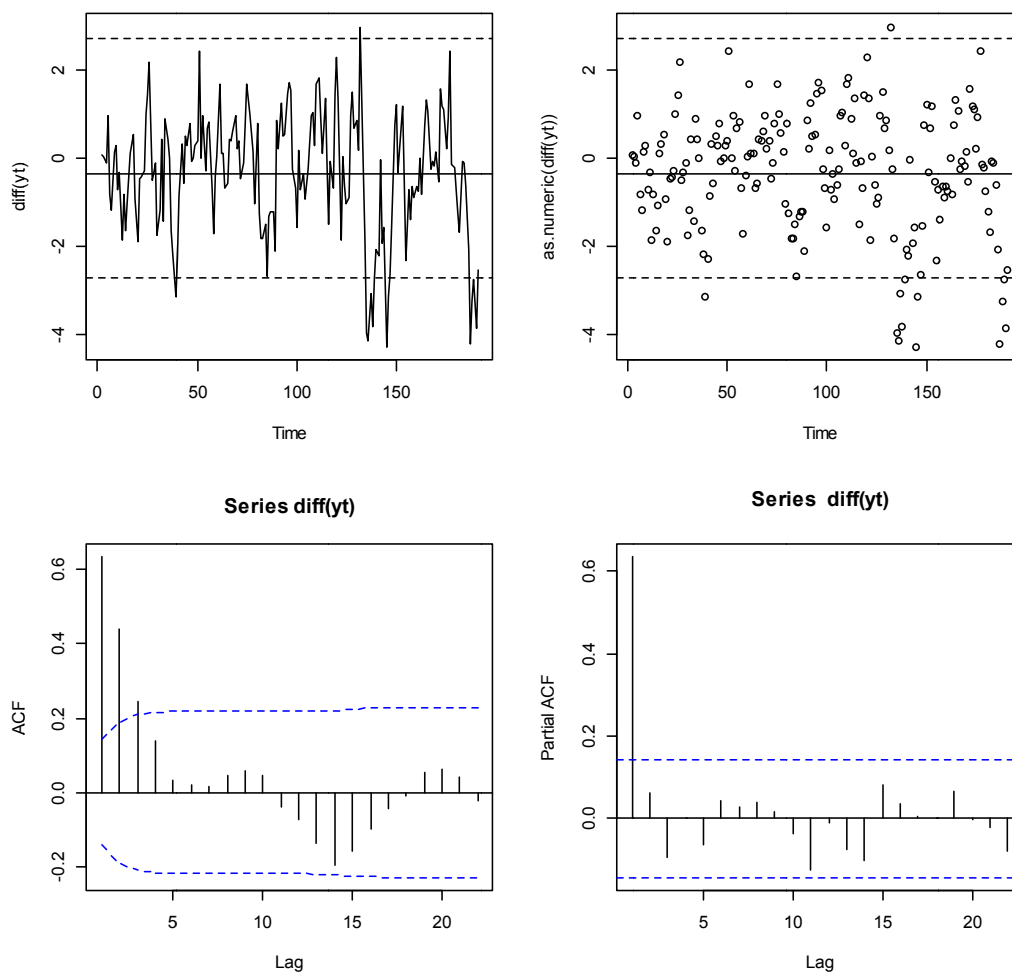


Figura 2: Primera diferencia con los $n=191$ primeros datos, su ACF y PACF

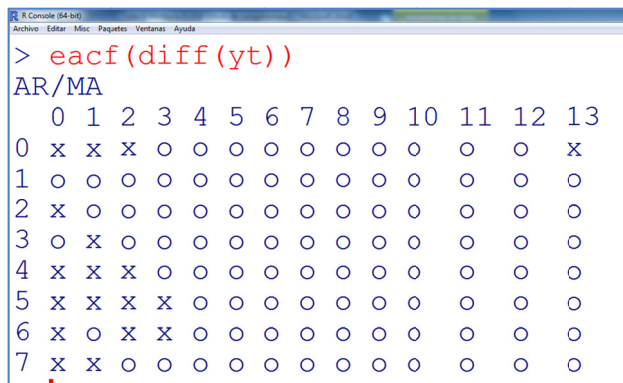



Figura 3: EACF de la primera diferencia con los $n=191$ primeros datos



Observe que la primera diferencia de los primero 191 datos tiene una media muestral que es distinta de cero!!!

```
> mean(diff(yt))
[1] -0.3400249
```

```
R Console (64-bit)
Archivo Editor Misc Paquetes Ventanas Ayuda

> autoarmafit(diff(yt))

Case No. 1

AR coefficient Standard deviation
0.561092      1.149094
0.052312      0.820622

MA coefficient Standard deviation
-0.089643     1.149149
-0.081511     0.126970

AIC      23.251782
Innovation variance  1.083582
Final gradient 5.523876e-02 -1.315073e-02 -6.681693e-02 -1.421383e-02
```

```
> auto.arima(diff(yt)) #auto.arima sobre serie diferencia
Series: diff(yt)
ARIMA(1,0,0) with non-zero mean

Coefficients:
      ar1      mean
      0.6405 -0.3566
s.e.  0.0558  0.2123


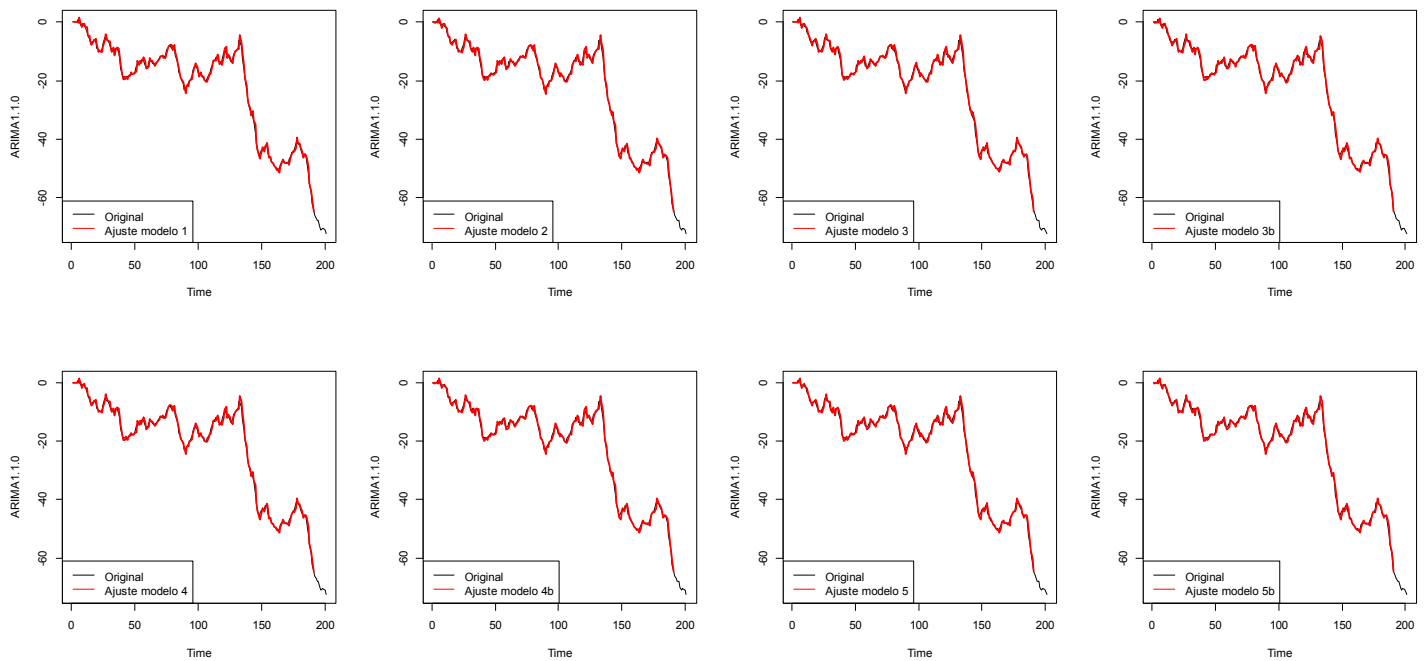
sigma^2 estimated as 1.139: log likelihood=-281.25
AIC=568.51 AICc=568.64 BIC=578.25
> auto.arima(yt) #auto.arima sobre serie sin diferenciar
Series: yt
ARIMA(1,1,0) with drift

Coefficients:
      ar1      drift
      0.6405 -0.3566
s.e.  0.0558  0.2123

sigma^2 estimated as 1.139: log likelihood=-281.25
AIC=568.51 AICc=568.64 BIC=578.25
> |
```

RESUMEN AJUSTES (Valores P bajo aproximación N(0,1))				
AJUSTE MODELO 1: ARIMA(1,1,0) sin deriva				
Parámetros	Estimación	Error estándar	Z ₀	P(Z > Z ₀)
ϕ_1	0.6616	0.0546	12.12001	< 2.2×10 ⁻¹⁶
Shapiro-Wilk normality test W = 0.9953, p-value = 0.8154				
AJUSTE MODELO 2: ARIMA(1,1,0) con deriva				
Parámetros	Estimación	Error estándar	Z ₀	P(Z > Z ₀)
ϕ_1	0.6405	0.0559	11.45301	< 2.2×10 ⁻¹⁶
δ	-0.3566	0.2129	-1.67490	0.0940
Shapiro-Wilk normality test W = 0.9953, p-value = 0.8148				
AJUSTE MODELO 3: ARIMA(2,1,1) sin deriva				
Parámetros	Estimación	Error estándar	Z ₀	P(Z > Z ₀)
ϕ_1	-0.0934	0.2440	-0.38270	0.7019
ϕ_2	0.5539	0.1497	3.69920	0.0002
θ_1	0.7063	0.2629	2.68656	0.0072
Shapiro-Wilk normality test W = 0.994, p-value = 0.6343				
AJUSTE MODELO 3b: ARIMA(2,1,1) con deriva				
Parámetros	Estimación	Error estándar	Z ₀	P(Z > Z ₀)
ϕ_1	-0.12301	0.23245	-0.5292	0.596655
ϕ_2	0.54270	0.13871	3.9124	9.139×10 ⁻⁰⁵
θ_1	0.71922	0.24844	2.8950	3.792×10 ⁻⁰³
δ	-0.35972	0.22457	-1.6018	0.109201
Shapiro-Wilk normality test W = 0.9944, p-value = 0.6907				
AJUSTE MODELO 4: ARIMA(1,1,1) sin deriva				
Parámetros	Estimación	Error estándar	Z ₀	P(Z > Z ₀)
ϕ_1	0.7240	0.0724	9.99915	1.537×10 ⁻²³
θ_1	-0.1083	0.0979	-1.10543	0.2690
Shapiro-Wilk normality test W = 0.9936, p-value = 0.574				
AJUSTE MODELO 4b: ARIMA(1,1,1) con deriva				
Parámetros	Estimación	Error estándar	Z ₀	P(Z > Z ₀)
ϕ_1	0.697849	0.076279	9.1487	< 2.2×10 ⁻¹⁶
θ_1	-0.095204	0.099282	-0.9589	0.3376
δ	-0.361760	0.227633	-1.5892	0.1120
Shapiro-Wilk normality test W = 0.99382, p-value = 0.61				
AJUSTE MODELO 5: ARIMA(2,1,2) sin deriva				
Parámetros	Estimación	Error estándar	Z ₀	P(Z > Z ₀)
ϕ_1	-0.080769	0.309080	-0.2613	0.79384
ϕ_2	0.535567	0.249007	2.1508	0.03149
θ_1	0.696578	0.318621	2.1862	0.02880
θ_2	0.013774	0.128256	0.1074	0.91447
Shapiro-Wilk normality test W = 0.99406, p-value = 0.6442				
AJUSTE MODELO 5b: ARIMA(2,1,2) con deriva				
Parámetros	Estimación	Error estándar	Z ₀	P(Z > Z ₀)
ϕ_1	-0.094275	0.356065	-0.2648	0.79119
ϕ_2	0.500985	0.279999	1.7892	0.07358
θ_1	0.696618	0.364929	1.9089	0.05627
θ_2	0.031185	0.135208	0.2306	0.81759
δ	-0.358301	0.220323	-1.6263	0.10390
Shapiro-Wilk normality test W = 0.99459, p-value = 0.7205				
Criterios de información con exp(C _n (p))				
	p	AIC	BIC	
modelo1	1	1.148930	1.168661	
modelo2	2	1.145220	1.184892	
modelo3	3	1.152733	1.213148	
modelo3b	4	1.150442	1.231529	
modelo4	2	1.153581	1.193544	
modelo4b	3	1.151691	1.212051	
modelo5	4	1.164796	1.246895	
modelo5b	5	1.162196	1.265478	

Ecuaciones teóricas y ajustadas	
Modelo 1: $(1 - \phi_1 B)(1 - B)Y_t = E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. Como $(1 - \phi_1 B)(1 - B) = 1 - (1 + \phi_1)B + \phi_1 B^2$, la ecuación final es: $Y_t = (1 + \phi_1)Y_{t-1} - \phi_1 Y_{t-2} + E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. Ecuación ajustada: $\hat{Y}_t = 1.6616Y_{t-1} - 0.6616Y_{t-2}$,	
Modelo2: $(1 - \phi_1 B)(1 - B)Y_t = \delta + E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. La ecuación final es $Y_t = \delta + (1 + \phi_1)Y_{t-1} - \phi_1 Y_{t-2} + E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. Ecuación ajustada: $\hat{Y}_t = -0.3566 + 1.6405Y_{t-1} - 0.6405Y_{t-2}$,	
Modelo 3: $(1 - \phi_1 B - \phi_2 B^2)(1 - B)Y_t = (1 + \theta_1 B)E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. Como $(1 - \phi_1 B - \phi_2 B^2)(1 - B) = 1 - (1 + \phi_1)B - (\phi_2 - \phi_1)B^2 + \phi_2 B^3$, la ecuación final es: $Y_t = (1 + \phi_1)Y_{t-1} + (\phi_2 - \phi_1)Y_{t-2} - \phi_2 Y_{t-3} + E_t + \theta_1 E_{t-1}, E_t \text{ un RB} \sim N(0, \sigma^2)$. Ecuación ajustada: $\hat{Y}_t = 0.9066Y_{t-1} + 0.6473Y_{t-2} - 0.5539Y_{t-3} + 0.7063\hat{E}_{t-1}$	
Modelo3b: $(1 - \phi_1 B - \phi_2 B^2)(1 - B)Y_t = \delta + (1 + \theta_1 B)E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. La ecuación final es: $Y_t = \delta + (1 + \phi_1)Y_{t-1} + (\phi_2 - \phi_1)Y_{t-2} - \phi_2 Y_{t-3} + E_t + \theta_1 E_{t-1}, E_t \text{ un RB} \sim N(0, \sigma^2)$. Ecuación ajustada: $\hat{Y}_t = -0.35972 + 0.87699Y_{t-1} + 0.66571Y_{t-2} - 0.54270Y_{t-3} + 0.71922\hat{E}_{t-1}$.	
Modelo4: $(1 - \phi_1 B)(1 - B)Y_t = (1 + \theta_1 B)E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. Como $(1 - \phi_1 B)(1 - B) = 1 - (1 + \phi_1)B + \phi_1 B^2$, la ecuación final es: $Y_t = (1 + \phi_1)Y_{t-1} - \phi_1 Y_{t-2} + E_t + \theta_1 E_{t-1}, E_t \text{ un RB} \sim N(0, \sigma^2)$. Ecuación ajustada: $\hat{Y}_t = 1.7240Y_{t-1} - 0.7240Y_{t-2} - 0.1083\hat{E}_{t-1}$.	
Modelo 4b: $(1 - \phi_1 B)(1 - B)Y_t = \delta + (1 + \theta_1 B)E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. La ecuación final es $Y_t = \delta + (1 + \phi_1)Y_{t-1} - \phi_1 Y_{t-2} + E_t + \theta_1 E_{t-1}, E_t \text{ un RB} \sim N(0, \sigma^2)$. Ecuación ajustada: $\hat{Y}_t = -0.361760 + 1.697849Y_{t-1} - 0.697849Y_{t-2} - 0.095204\hat{E}_{t-1}$.	
Modelo 5: $(1 - \phi_1 B - \phi_2 B^2)(1 - B)Y_t = (1 + \theta_1 B + \theta_2 B^2)E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. Como $(1 - \phi_1 B - \phi_2 B^2)(1 - B) = 1 - (1 + \phi_1)B - (\phi_2 - \phi_1)B^2 + \phi_2 B^3$, la ecuación final es: $Y_t = (1 + \phi_1)Y_{t-1} + (\phi_2 - \phi_1)Y_{t-2} - \phi_2 Y_{t-3} + E_t + \theta_1 E_{t-1} + \theta_2 E_{t-2}, E_t \text{ un RB} \sim N(0, \sigma^2)$. Ecuación ajustada: $\hat{Y}_t = 0.919231Y_{t-1} + 0.616336Y_{t-2} - 0.535567Y_{t-3} + 0.696578\hat{E}_{t-1} + 0.013774\hat{E}_{t-2}$	
Modelo5b: $(1 - \phi_1 B - \phi_2 B^2)(1 - B)Y_t = \delta + (1 + \theta_1 B + \theta_2 B^2)E_t, E_t \text{ un RB} \sim N(0, \sigma^2)$. La ecuación final es: $Y_t = \delta + (1 + \phi_1)Y_{t-1} + (\phi_2 - \phi_1)Y_{t-2} - \phi_2 Y_{t-3} + E_t + \theta_1 E_{t-1} + \theta_2 E_{t-2}, E_t \text{ un RB} \sim N(0, \sigma^2)$. Ecuación ajustada: $\hat{Y}_t = -0.358301 + 0.905725Y_{t-1} + 0.59526Y_{t-2} - 0.500985Y_{t-3} + 0.696618\hat{E}_{t-1} + 0.031185\hat{E}_{t-2}$	
Nota: En las ecuaciones ajustadas de los modelos que tienen parte MA, \hat{E}_{t-j} es el residuo del ajuste para el tiempo $t - j$ y los residuos de ajuste para cualquier tiempo t corresponden a $\hat{E}_t = Y_t - \hat{Y}_t$ y con base en estos residuos se construyen las gráficas y tests para validar supuestos sobre el error de ajuste E_t : Proceso Ruido Blanco distribuido $N(0, \sigma^2)$	



	Amplitud	I.P	Cobertura	RMSE	MAE	MAPE
modelo1	19.71		100	1.38	1.13	1.60
modelo2	18.99		100	0.69	0.61	0.88
modelo3	19.98		100	0.93	0.75	1.08
modelo3b	19.27		100	1.10	0.93	1.35
modelo4	19.94		100	0.83	0.64	0.92
modelo4b	19.22		100	1.26	1.10	1.58
modelo5	20.02		100	0.97	0.81	1.16
modelo5b	19.29		100	0.95	0.79	1.14

Ecuaciones de pronóstico con origen en $t=191$: En las siguientes ecuaciones, $\hat{Y}_{191}(L)$ es el pronóstico L periodos después de $t=191$;

$$\hat{Y}_{191}(L-j) = \begin{cases} \text{Observación } Y_{191+L-j}, & \text{si } L-j \leq 0 \\ \text{Pronóstico } L-j \text{ periodos después de } t=191, & \text{si } L-j > 0 \end{cases}$$

$$\hat{E}_{191}(L-i) = \begin{cases} \text{Residuo } \hat{E}_{191+L-i}, & \text{si } L-i \leq 0 \\ 0, & \text{si } L-i > 0 \end{cases}$$

Modelo 1:

$$\hat{Y}_{191}(L) = 1.6616\hat{Y}_{191}(L-1) - 0.6616\hat{Y}_{191}(L-2).$$

Modelo 2:

$$\hat{Y}_{191}(L) = -0.3566 + 1.6405\hat{Y}_{191}(L-1) - 0.6405\hat{Y}_{191}(L-2).$$

Modelo 3:

$$\hat{Y}_{191}(L) = 0.9066\hat{Y}_{191}(L-1) + 0.6473\hat{Y}_{191}(L-2) - 0.5539\hat{Y}_{191}(L-3) + 0.7063\hat{E}_{191}(L-1).$$

Modelo 3b:

$$\hat{Y}_{191}(L) = -0.35972 + 0.87699\hat{Y}_{191}(L-1) + 0.66571\hat{Y}_{191}(L-2) + -0.54270\hat{Y}_{191}(L-3) + 0.71922\hat{E}_{191}(L-1).$$

Modelo 4:

$$\hat{Y}_{191}(L) = 1.7240\hat{Y}_{191}(L-1) - 0.7240\hat{Y}_{191}(L-2) - 0.1083\hat{E}_{191}(L-1).$$

Modelo 4b:

$$\hat{Y}_{191}(L) = -0.361760 + 1.697849\hat{Y}_{191}(L-1) - 0.697849\hat{Y}_{191}(L-2) + -0.095204\hat{E}_{191}(L-1).$$

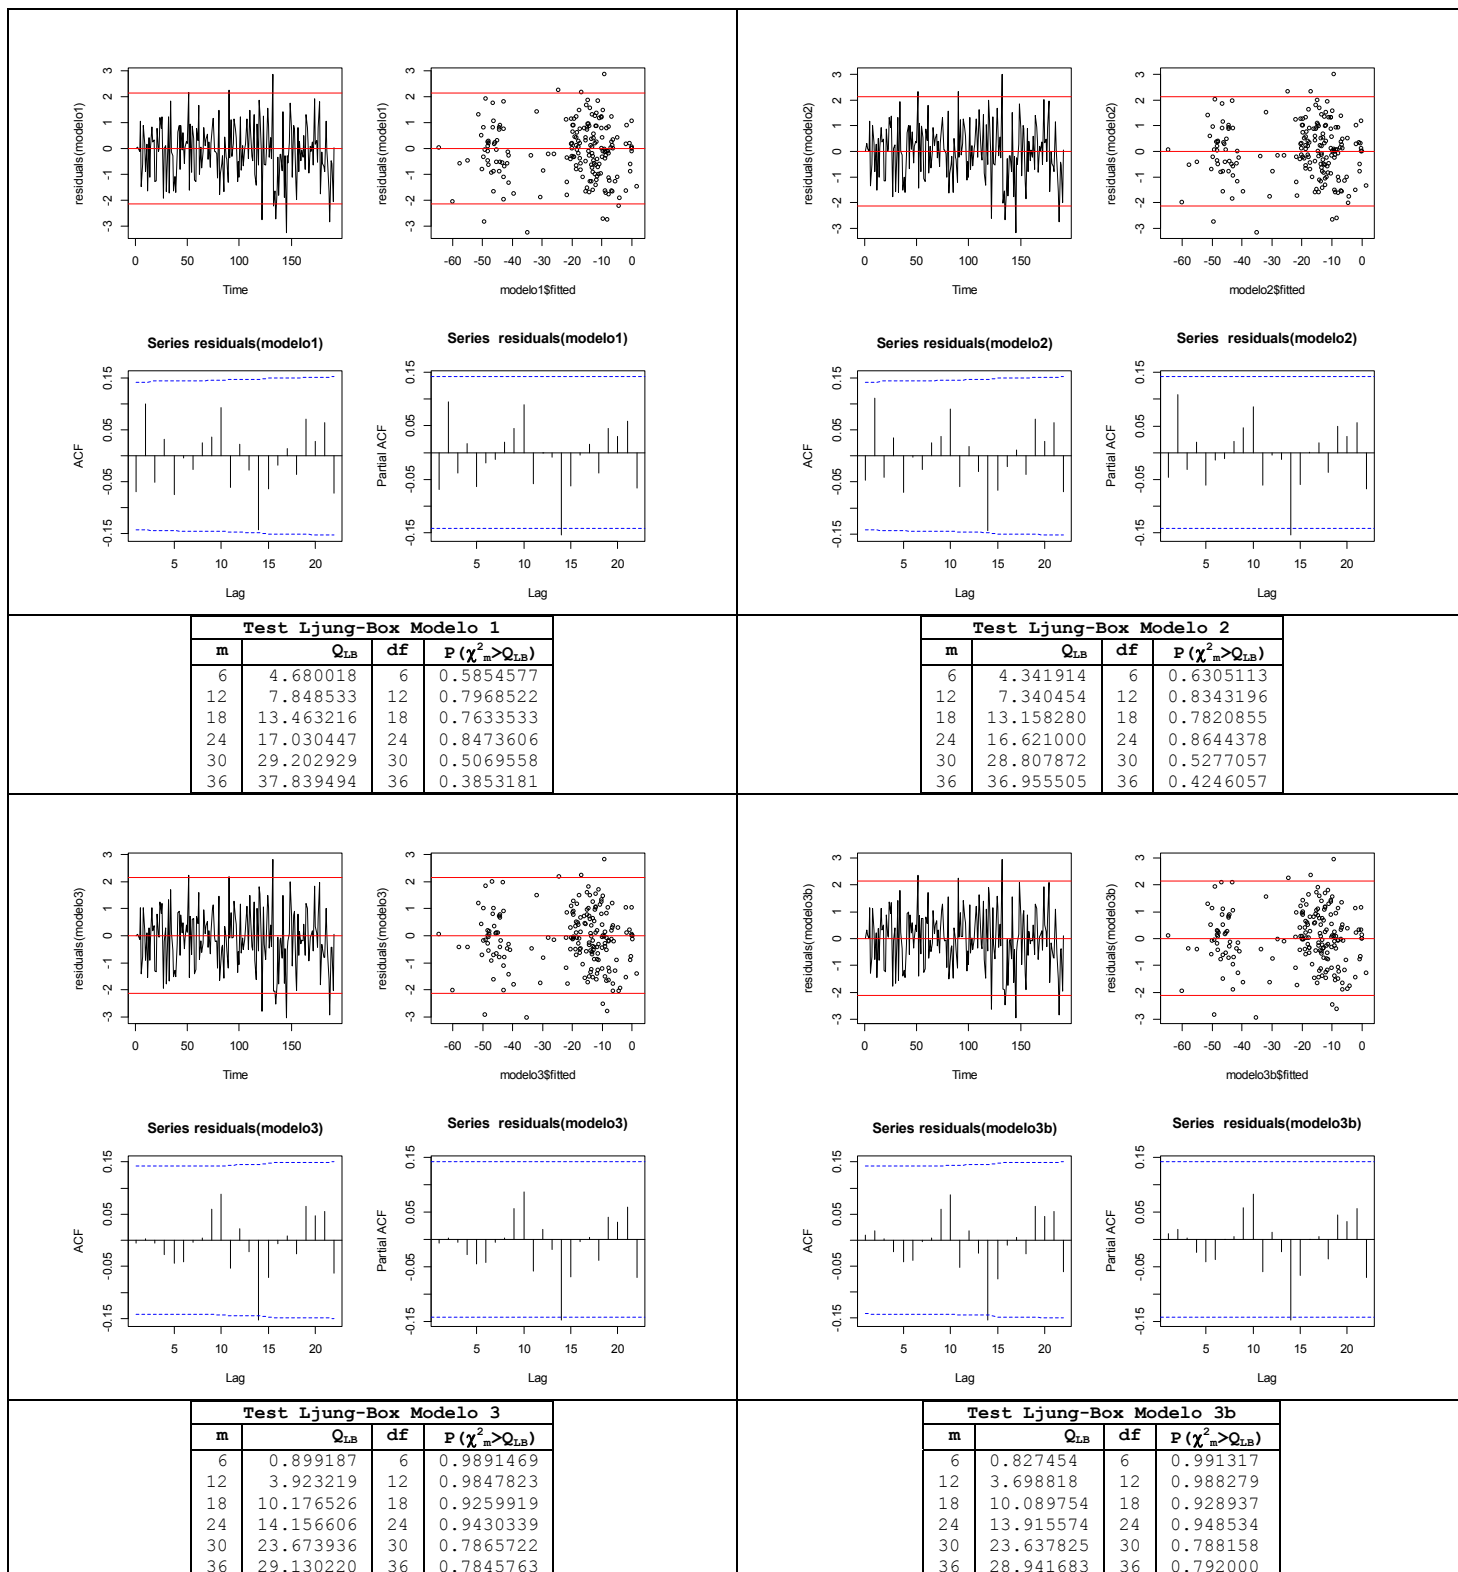
Modelo 5:

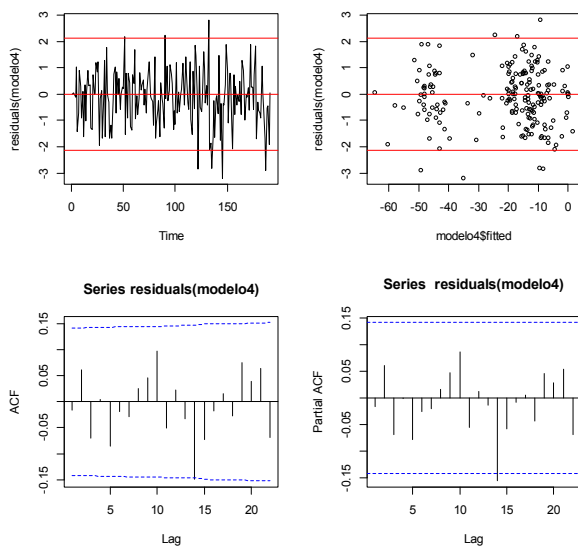
$$\hat{Y}_{191}(L) = 0.919231\hat{Y}_{191}(L-1) + 0.616336\hat{Y}_{191}(L-2) - 0.535567\hat{Y}_{191}(L-3) + 0.696578\hat{E}_{191}(L-1) + 0.013774\hat{E}_{191}(L-2).$$

Modelo 5b:

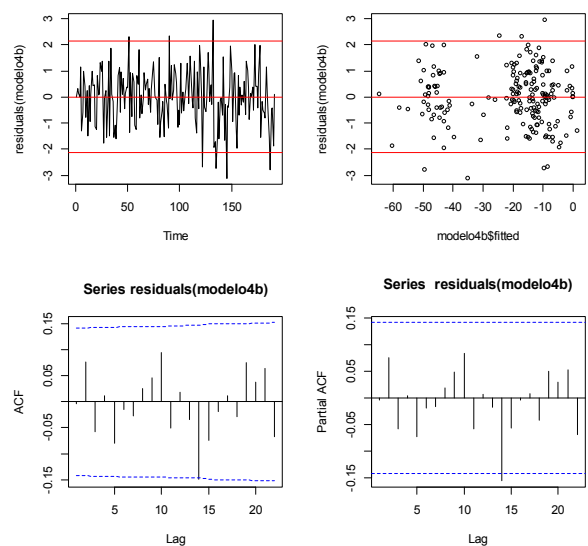
$$\hat{Y}_{191}(L) = -0.358301 + 0.905725\hat{Y}_{191}(L-1) + 0.59526\hat{Y}_{191}(L-2) + -0.500985\hat{Y}_{191}(L-3) + 0.696618\hat{E}_{191}(L-1) + 0.031185\hat{E}_{191}(L-2).$$

En la validación de supuestos recuerde que es sobre el error de ajuste, en este caso, E_t y por tanto, definimos en tests ACF y Ljung-Box, $\rho(k) = \text{corr}(E_t, E_{t+k})$ y en tests PACF definimos $\phi_{kk} = \text{corr}(E_t, E_{t+k} | E_{t+1}, \dots, E_{t+k-1})$, siendo los estimadores de estas funciones, respectivamente, $\hat{\rho}(k) = \widehat{\text{corr}}(E_t, E_{t+k}) = \frac{\sum_{t=1}^{191-k} \hat{E}_t \hat{E}_{t+k}}{\sum_{t=1}^{191} \hat{E}_t^2} \sim \text{aprox. } N\left(0, \frac{1}{191}\right)$ y $\hat{\phi}_{kk} = \widehat{\text{corr}}(E_t, E_{t+k} | E_{t+1}, \dots, E_{t+k-1}) \sim \text{aprox. } N\left(0, \frac{1}{191}\right)$. Para tests ACF y PACF se consideró $k = 1, 2, \dots, 22$, y para Ljung-Box $m = 6, 12, 18, 24, 30, 36$. También test Shapiro es sobre el error de ajuste E_t .

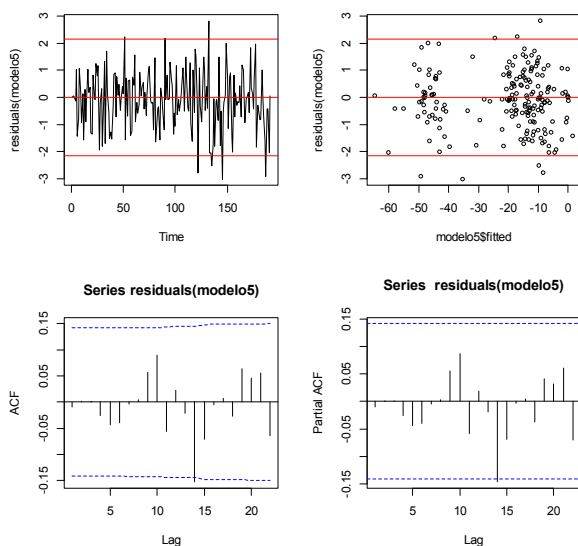




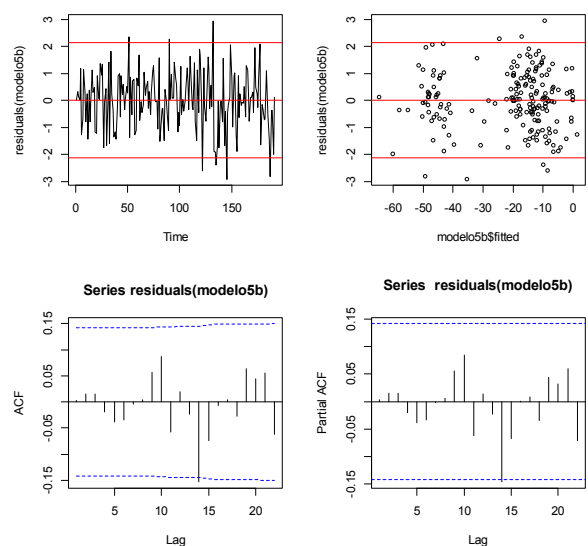
Test Ljung-Box Modelo 4			
m	Q_{LB}	df	$P(\chi^2_m > Q_{LB})$
6	3.280698	6	0.7728806
12	6.553030	12	0.8856846
18	12.768151	18	0.8051582
24	16.641109	24	0.8635597
30	27.365525	30	0.6040198
36	34.494714	36	0.5402204



Test Ljung-Box Modelo 4b			
m	Q_{LB}	df	$P(\chi^2_m > Q_{LB})$
6	3.125207	6	0.792976
12	6.222879	12	0.904432
18	12.528925	18	0.818764
24	16.257405	24	0.878562
30	27.231299	30	0.611101
36	34.128412	36	0.557841



Test Ljung-Box Modelo 5			
m	Q_{LB}	df	$P(\chi^2_m > Q_{LB})$
6	0.834551	6	0.991115
12	3.895069	12	0.985256
18	10.103823	18	0.928465
24	14.089916	24	0.944593
30	23.737946	30	0.783749
36	29.226580	36	0.780736



Test Ljung-Box Modelo 5b			
m	Q_{LB}	df	$P(\chi^2_m > Q_{LB})$
6	0.703133	6	0.994423
12	3.651127	12	0.988941
18	9.949504	18	0.933542
24	13.784760	24	0.951363
30	23.805434	30	0.780755
36	29.195847	36	0.781964

Código R 1.0: Cargando librerías y definiendo funciones de usuario

```
library(forecast); library(timsac); library(TSA); library(lmtest)
```

#Creando función usuario para obtener test Box-Pierce y Ljung-Box

```
BP.LB.test=function(serie,maxlag,type="Box"){
  aux=floor(maxlag/6);
  X.squared=c(rep(NA,aux))
  df=c(rep(NA,aux))
  p.value=c(rep(NA,aux))
  for(i in 1:aux){
    test=Box.test(serie,lag=(6*i),type=type)
    X.squared[i]=test[[1]]
    df[i]=test[[2]]
    p.value[i]=test[[3]]
  }
  lag=6*c(1:aux)
  teste=as.data.frame(cbind(X.squared,df,p.value))
  rownames(teste)=lag
  teste
}
```

#Creando función usuario crit.inf.resid() para calcular $C_n^{*}(p)$

```
crit.inf.resid=function(residuales,n.par,AIC="TRUE"){
  if(AIC=="TRUE"){
    #Calcula AIC
    CI=log(mean(residuales^2))+2*n.par/length(residuales)
  }
  if(AIC=="FALSE"){
    #Calcula BIC
    CI=log(mean(residuales^2))+n.par*log(length(residuales))/length(residuales)
  }
  CI
}
```

#Función para calcular la amplitud de los I.P

```
amplitud=function(LIP,LSP){
  a=LSP-LIP
  am=mean(a)
  am
}
```

#Función para calcular la cobertura de los I.P

```
cobertura=function(real,LIP,LSP){
  I=ifelse(real>=LIP & real<=LSP,1,0)
  p=mean(I)
  p
}
```

Código R 2.0: Lectura datos y gráficos serie, primera diferencia y sus ACF's muestrales

```
ARIMA1.1.0=ts(scan(file.choose(),skip=1),freq=1)#leer ARIMA110.SIMUL.txt
layout(rbind(c(1,1,2,2),c(3,3,4,4)))
plot(ARIMA1.1.0)
acf(ARIMA1.1.0,ci.type="ma")
plot(diff(ARIMA1.1.0))
abline(h=mean(diff(ARIMA1.1.0)))
abline(h=c(-2*sd(diff(ARIMA1.1.0)),2*sd(diff(ARIMA1.1.0))),lty=2)
acf(diff(ARIMA1.1.0),ci.type="ma")
```

Código R 3.0: Identificación de modelos ARIMA usando sólo los primeros n=191 datos

```
n=length(ARIMA1.1.0)-10
t=1:n
yt=ts(ARIMA1.1.0[t],freq=1) #serie con sólo 191 datos

layout(rbind(c(1,1,2,2),c(3,3,4,4)))
plot(diff(yt))
abline(h=mean(diff(ARIMA1.1.0)))
abline(h=c(-2*sd(diff(ARIMA1.1.0)),2*sd(diff(ARIMA1.1.0))),lty=2)
plot(time(diff(yt)),as.numeric(diff(yt)),xlab="Time")
abline(h=mean(diff(ARIMA1.1.0)))
abline(h=c(-2*sd(diff(ARIMA1.1.0)),2*sd(diff(ARIMA1.1.0))),lty=2)
acf(diff(yt),ci.type="ma")
pacf(diff(yt))
eacf(diff(yt))

win.graph()
plot(armasubsets(diff(yt),nar=12,nma=12,y.name='test',ar.method='ml'))

autoarmafit(diff(yt)) #identificando ARMA's sobre serie diferencia
auto.arima(diff(yt)) #auto.arima sobre serie diferencia identifica ARIMA(p,0,q)
auto.arima(yt) #auto.arima sobre serie sin diferenciar identifica ARIMA(p,d,q)

mean(diff(yt)) #verificando media
```


Código R 4.0: Ajustes modelos ARIMA usando sólo los primeros n=191 datos (Valores P para significancia de parámetros calculados bajo N(0,1))

4.1 Modelo 1: ARIMA(1,1,0) sin deriva

```
modelo1=Arima(yt,order=c(1,1,0),method="ML")
coeftest(modelo1)

layout(rbind(c(1,2),c(3,4)))
plot.ts(residuals(modelo1))
abline(h=c(-2*sqrt(modelo1$sigma2),0,2*sqrt(modelo1$sigma2)),col=2)
plot(modelo1$fitted,residuals(modelo1))
abline(h=c(-2*sqrt(modelo1$sigma2),0,2*sqrt(modelo1$sigma2)),col=2)
acf(residuals(modelo1),ci.type="ma")
pacf(residuals(modelo1))

BP.LB.test(residuals(modelo1),maxlag=36,type="Ljung")
shapiro.test(residuals(modelo1))
```

4.2. Modelo 2: ARIMA(1,1,0) con deriva

```
modelo2=Arima(yt,order=c(1,1,0),include.drift=TRUE,method="ML")
coeftest(modelo2)

layout(rbind(c(1,2),c(3,4)))
plot.ts(residuals(modelo2))
abline(h=c(-2*sqrt(modelo2$sigma2),0,2*sqrt(modelo2$sigma2)),col=2)
plot(modelo2$fitted,residuals(modelo2))
abline(h=c(-2*sqrt(modelo2$sigma2),0,2*sqrt(modelo2$sigma2)),col=2)
acf(residuals(modelo2),ci.type="ma")
pacf(residuals(modelo2))

BP.LB.test(residuals(modelo2),maxlag=36,type="Ljung")
shapiro.test(residuals(modelo2))
```

4.3. Modelo3: ARIMA(2,1,1) sin deriva

```
modelo3=Arima(yt,order=c(2,1,1),method="ML")
coeftest(modelo3)

layout(rbind(c(1,2),c(3,4)))
plot.ts(residuals(modelo3))
abline(h=c(-2*sqrt(modelo3$sigma2),0,2*sqrt(modelo3$sigma2)),col=2)
plot(modelo3$fitted,residuals(modelo3))
abline(h=c(-2*sqrt(modelo3$sigma2),0,2*sqrt(modelo3$sigma2)),col=2)
acf(residuals(modelo3),ci.type="ma")
pacf(residuals(modelo3))

BP.LB.test(residuals(modelo3),maxlag=36,type="Ljung")
shapiro.test(residuals(modelo3))
```

4.4. Modelo3b: ARIMA(2,1,1) con deriva

```
modelo3b=Arima(yt,order=c(2,1,1),include.drift=TRUE,method="ML")
coeftest(modelo3b)

layout(rbind(c(1,2),c(3,4)))
plot.ts(residuals(modelo3b))
abline(h=c(-2*sqrt(modelo3b$sigma2),0,2*sqrt(modelo3b$sigma2)),col=2)
plot(modelo3b$fitted,residuals(modelo3b))
abline(h=c(-2*sqrt(modelo3b$sigma2),0,2*sqrt(modelo3b$sigma2)),col=2)
acf(residuals(modelo3b),ci.type="ma")
pacf(residuals(modelo3b))

BP.LB.test(residuals(modelo3b),maxlag=36,type="Ljung")
shapiro.test(residuals(modelo3b))
```

4.5. Modelo4: ARIMA(1,1,1) sin deriva

```
modelo4=Arima(yt,order=c(1,1,1),method="ML")
coeftest(modelo4)

layout(rbind(c(1,2),c(3,4)))
plot.ts(residuals(modelo4))
abline(h=c(-2*sqrt(modelo4$sigma2),0,2*sqrt(modelo4$sigma2)),col=2)
plot(modelo4$fitted,residuals(modelo4))
abline(h=c(-2*sqrt(modelo4$sigma2),0,2*sqrt(modelo4$sigma2)),col=2)
acf(residuals(modelo4),ci.type="ma")
pacf(residuals(modelo4))

BP.LB.test(residuals(modelo4),maxlag=36,type="Ljung")
shapiro.test(residuals(modelo4))
```

4.6. Modelo4b: ARIMA(1,1,1) con deriva

```
modelo4b=Arima(yt,order=c(1,1,1),include.drift=TRUE,method="ML")
coeftest(modelo4b)

layout(rbind(c(1,2),c(3,4)))
plot.ts(residuals(modelo4b))
abline(h=c(-2*sqrt(modelo4b$sigma2),0,2*sqrt(modelo4b$sigma2)),col=2)
plot(modelo4b$fitted,residuals(modelo4b))
abline(h=c(-2*sqrt(modelo4b$sigma2),0,2*sqrt(modelo4b$sigma2)),col=2)
acf(residuals(modelo4b),ci.type="ma")
pacf(residuals(modelo4b))
```

```
BP.LB.test(residuals(modelo4b),maxlag=36,type="Ljung")
shapiro.test(residuals(modelo4b))
```

4.7. Modelo5: ARIMA(2,1,2) sin deriva

```
modelo5=Arima(yt,order=c(2,1,2),method="ML")
coeftest(modelo5)

layout(rbind(c(1,2),c(3,4)))
plot.ts(residuals(modelo5))
abline(h=c(-2*sqrt(modelo5$sigma2),0,2*sqrt(modelo5$sigma2)),col=2)
plot(modelo5$fitted,residuals(modelo5))
abline(h=c(-2*sqrt(modelo5$sigma2),0,2*sqrt(modelo5$sigma2)),col=2)
acf(residuals(modelo5),ci.type="ma")
pacf(residuals(modelo5))

BP.LB.test(residuals(modelo5),maxlag=36,type="Ljung")
shapiro.test(residuals(modelo5))
```

4.8. Modelo5b: ARIMA(2,1,2) con deriva

```
modelo5b=Arima(yt,order=c(2,1,2),include.drift=T,method="ML")
coeftest(modelo5b)

layout(rbind(c(1,2),c(3,4)))
plot.ts(residuals(modelo5b))
abline(h=c(-2*sqrt(modelo5b$sigma2),0,2*sqrt(modelo5b$sigma2)),col=2)
plot(modelo5b$fitted,residuals(modelo5b))
abline(h=c(-2*sqrt(modelo5b$sigma2),0,2*sqrt(modelo5b$sigma2)),col=2)
acf(residuals(modelo5b),ci.type="ma")
pacf(residuals(modelo5b))

BP.LB.test(residuals(modelo5b),maxlag=36,type="Ljung")
shapiro.test(residuals(modelo5b))
```

4.9 Gráficas de los ajustes y medidas de bondad de ajuste

```
win.graph(width=16,height=8)
layout(rbind(c(1,2,3,4),c(5,6,7,8)))plot(ARIMA1.1.0)
lines(modelo1$fitted,col=2,lwd=2)
legend("bottomleft",legend=c("Original","Ajuste modelo 1"),col=1:2,lty=1)
plot(ARIMA1.1.0)
lines(modelo2$fitted,col=2,lwd=2)
legend("bottomleft",legend=c("Original","Ajuste modelo 2"),col=1:2,lty=1)
plot(ARIMA1.1.0)
lines(modelo3$fitted,col=2,lwd=2)
legend("bottomleft",legend=c("Original","Ajuste modelo 3"),col=1:2,lty=1)
plot(ARIMA1.1.0)
lines(modelo3b$fitted,col=2,lwd=2)
legend("bottomleft",legend=c("Original","Ajuste modelo 3b"),col=1:2,lty=1)
plot(ARIMA1.1.0)
lines(modelo4$fitted,col=2,lwd=2)
legend("bottomleft",legend=c("Original","Ajuste modelo 4"),col=1:2,lty=1)
plot(ARIMA1.1.0)
lines(modelo4b$fitted,col=2,lwd=2)
legend("bottomleft",legend=c("Original","Ajuste modelo 4b"),col=1:2,lty=1)
plot(ARIMA1.1.0)
lines(modelo5$fitted,col=2,lwd=2)
legend("bottomleft",legend=c("Original","Ajuste modelo 5"),col=1:2,lty=1)
plot(ARIMA1.1.0)
lines(modelo5b$fitted,col=2,lwd=2)
legend("bottomleft",legend=c("Original","Ajuste modelo 5b"),col=1:2,lty=1)

aic1=exp(crit.inf.resid(residuals(modelo1),n.par=1))
aic2=exp(crit.inf.resid(residuals(modelo2),n.par=2))
aic3=exp(crit.inf.resid(residuals(modelo3),n.par=3))
aic3b=exp(crit.inf.resid(residuals(modelo3b),n.par=4))
aic4=exp(crit.inf.resid(residuals(modelo4),n.par=2))
aic4b=exp(crit.inf.resid(residuals(modelo4b),n.par=3))
aic5=exp(crit.inf.resid(residuals(modelo5),n.par=4))
aic5b=exp(crit.inf.resid(residuals(modelo5b),n.par=5))

bic1=exp(crit.inf.resid(residuals(modelo1),n.par=1,AIC="FALSE"))
bic2=exp(crit.inf.resid(residuals(modelo2),n.par=2,AIC="FALSE"))
bic3=exp(crit.inf.resid(residuals(modelo3),n.par=3,AIC="FALSE"))
bic3b=exp(crit.inf.resid(residuals(modelo3b),n.par=4,AIC="FALSE"))
bic4=exp(crit.inf.resid(residuals(modelo4),n.par=2,AIC="FALSE"))
bic4b=exp(crit.inf.resid(residuals(modelo4b),n.par=3,AIC="FALSE"))
bic5=exp(crit.inf.resid(residuals(modelo5),n.par=4,AIC="FALSE"))
bic5b=exp(crit.inf.resid(residuals(modelo5b),n.par=5,AIC="FALSE"))

criterios=data.frame(p=c(1,2,3,4,2,3,4,5),AIC=c(aic1,aic2,aic3,aic3b,aic4,aic4b,aic5,aic5b),BIC=c(bic1,bic2,bic3,bic3b,bic4,bic4b,bic5,bic5b),row.names=c("modelo1","modelo2","modelo3","modelo3b","modelo4","modelo4b","modelo5","modelo5b"))
criterios
```

4.10 Predicciones de las últimas 10 observaciones con I.P del 95% y medidas de precisión pronósticos

```
tNuevo=(n+1):length(ARIMA1.1.0) #valor índice de tiempo en los pronósticos
ynuevo=ts(ARIMA1.1.0[tNuevo],freq=1,start=192) #valor serie en las últimos 10 tiempo

pred1=forecast(modelo1,h=10,level=95)
pred1=cbind(Predic=pred1$mean,LIP95=pred1$lower,LSP95=pred1$upper)
pred2=forecast(modelo2,h=10,level=95)
pred2=cbind(Predic=pred2$mean,LIP95=pred2$lower,LSP95=pred2$upper)
pred3=forecast(modelo3,h=10,level=95)
pred3=cbind(Predic=pred3$mean,LIP95=pred3$lower,LSP95=pred3$upper)
pred3b=forecast(modelo3b,h=10,level=95)
pred3b=cbind(Predic=pred3b$mean,LIP95=pred3b$lower,LSP95=pred3b$upper)
pred4=forecast(modelo4,h=10,level=95)
pred4=cbind(Predic=pred4$mean,LIP95=pred4$lower,LSP95=pred4$upper)
pred4b=forecast(modelo4b,h=10,level=95)
pred4b=cbind(Predic=pred4b$mean,LIP95=pred4b$lower,LSP95=pred4b$upper)
pred5=forecast(modelo5,h=10,level=95)
pred5=cbind(Predic=pred5$mean,LIP95=pred5$lower,LSP95=pred5$upper)
pred5b=forecast(modelo5b,h=10,level=95)
pred5b=cbind(Predic=pred5b$mean,LIP95=pred5b$lower,LSP95=pred5b$upper)

#Gráfico comparativo de predicciones puntuales vs. valores reales
plot(ynuevo,col="brown",lwd=2,type="b",pch=19,ylim=c(-73,-65))
lines(pred1[,1],col=2,lwd=2,type="b",pch=1)
lines(pred2[,1],col=3,lwd=2,type="b",pch=2)
lines(pred3[,1],col=4,lwd=2,type="b",pch=3)
lines(pred3b[,1],col=5,lwd=2,type="b",pch=4)
lines(pred4[,1],col=6,lwd=2,type="b",pch=5)
lines(pred4b[,1],col=7,lwd=2,type="b",pch=6)
lines(pred5[,1],col=8,lwd=2,type="b",pch=7)
lines(pred5b[,1],col=9,lwd=2,type="b",pch=8)
legend("topright",legend=c("Original","pred1","Pred2","Pred3","pred3b","Pred4","Pred4b","Pred5","Pred5b"),col=c("brown",2:9),
pch=c(19,1:8),lty=1,lwd=2)

#Amplitud I.P
amp1=amplitud(LIP=pred1[,2],LSP=pred1[,3])
amp2=amplitud(LIP=pred2[,2],LSP=pred2[,3])
amp3=amplitud(LIP=pred3[,2],LSP=pred3[,3])
amp3b=amplitud(LIP=pred3b[,2],LSP=pred3b[,3])
amp4=amplitud(LIP=pred4[,2],LSP=pred4[,3])
amp4b=amplitud(LIP=pred4b[,2],LSP=pred4b[,3])
amp5=amplitud(LIP=pred5[,2],LSP=pred5[,3])
amp5b=amplitud(LIP=pred5b[,2],LSP=pred5b[,3])

#Cobertura I.P
cob1=cobertura(real=ynuevo,LIP=pred1[,2],LSP=pred1[,3])
cob2=cobertura(real=ynuevo,LIP=pred2[,2],LSP=pred2[,3])
cob3=cobertura(real=ynuevo,LIP=pred3[,2],LSP=pred3[,3])
cob3b=cobertura(real=ynuevo,LIP=pred3b[,2],LSP=pred3b[,3])
cob4=cobertura(real=ynuevo,LIP=pred4[,2],LSP=pred4[,3])
cob4b=cobertura(real=ynuevo,LIP=pred4b[,2],LSP=pred4b[,3])
cob5=cobertura(real=ynuevo,LIP=pred5[,2],LSP=pred5[,3])
cob5b=cobertura(real=ynuevo,LIP=pred5b[,2],LSP=pred5b[,3])

#Tabla con todas las medidas de precisión de pronósticos
tablaprec=data.frame(AmplitudI.P=c(amp1,amp2,amp3,amp3b,amp4,amp4b,amp5,amp5b),Cobertura=c(cob1,cob2,cob3,cob3b,cob4,cob4b,cob5,
cob5b)*100,
RMSE=c(accuracy(pred1[,1],ynuevo)[2],accuracy(pred2[,1],ynuevo)[2],accuracy(pred3[,1],ynuevo)[2],accuracy(pred3b[,1],ynuevo)[2],
accuracy(pred4[,1],ynuevo)[2],accuracy(pred4b[,1],ynuevo)[2],accuracy(pred5[,1],ynuevo)[2],accuracy(pred5b[,1],ynuevo)[2]),
MAE=c(accuracy(pred1[,1],ynuevo)[3],accuracy(pred2[,1],ynuevo)[3],accuracy(pred3[,1],ynuevo)[3],accuracy(pred3b[,1],ynuevo)[3],a
ccuracy(pred4[,1],ynuevo)[3],accuracy(pred4b[,1],ynuevo)[3],accuracy(pred5[,1],ynuevo)[3],accuracy(pred5b[,1],ynuevo)[3]),
MAPE=c(accuracy(pred1[,1],ynuevo)[5],accuracy(pred2[,1],ynuevo)[5],accuracy(pred3[,1],ynuevo)[5],accuracy(pred3b[,1],ynuevo)[5],
accuracy(pred4[,1],ynuevo)[5],accuracy(pred4b[,1],ynuevo)[5],accuracy(pred5[,1],ynuevo)[5],accuracy(pred5b[,1],ynuevo)[5]),
row.names=c("modelo1","modelo2","modelo3","modelo3b","modelo4","modelo4b","modelo5","modelo5b"))
round(tablaprec,digits=2)
```